

# **Predikcija koncentracije PM2.5 primenom mašinskog učenja**


**Nikolina Šormaz 4008/2024**

**Ana Sofronijević 4016/2024**


# Sadržaj projekta

- 01 Analiza skupa podataka
- 02 Linearna regresija i ElasticNet
- 03 SVM
- 04 KNN
- 05 Random Forest
- 06 Potpuno povezana neuronska mreža


# Analiza podataka



- **Kategorički atribut cbwd opisuje smer vetra kroz četiri kategorije ( SE, NW, NE i cv )**




- **Distribucija ciljne promenljive PM2.5 pomoću histograma**






- Analiza Pirsonovog koeficijenta korelacije pokazuje da nijedan atribut nema jaku linearnu vezu sa PM2.5 , najizraženiji su Iws (  $\approx -0,25$  ) i DEWP (  $\approx 0,17$  ).
- Slabe linearne veze ukazuju da odnos meteoroloških uslova i PM2.5 zahteva složenije, nelinearne modele.

- Korelaciona matrica pokazuje jaku međusobnu povezanost pojedinih meteoroloških atributa , DEWP–TEMP (  $\approx 0,82$  ), TEMP–PRES (  $\approx -0,83$  ) i DEWP–PRES (  $\approx -0,78$  ).
- Ovi atributi nose delom istu informaciju, što treba imati u vidu pri interpretaciji regresionih modela.



# Vremenska analiza koncentracije PM2.5



- Uočava se sezonski obrazac, pri čemu su vrednosti PM2.5 više tokom hladnijih meseci, a niže tokom toplijih, pa mesec može biti značajan za predikciju.
- Nivo zagađenja se menja i tokom dana, sa periodima viših i nižih koncentracija, što ukazuje na dnevni obrazac i korisnost vremenskih atributa.
- Prosečna koncentracija varira iz godine u godinu bez pravilnog obrasca, uslovljena spoljašnjim faktorima specifičnim za svaku godinu.

# Linearna regresija

## Train

**R2: 0.2796386427278953**

**MAE: 56.75845411475262**

**RMSE: 77.97225797544415**

## Validation

**R2: 0.2735171643694503**

**MAE: 55.45700671129612**

**RMSE: 76.18916826739125**

## Test

**R2: 0.26815196521767337**

**MAE: 57.603333416856394**

**RMSE: 79.89597212472071**

- Osnovni model linearne regresije ima ograničenu moć predikcije PM2.5, što je u skladu sa početnom analizom koja nije pokazala jaku linearnu povezanost atributa sa ciljnom promenljivom

# Linearna regresija sa ElasticNet


## ElasticNet Test

**R2: 0.2680592933316156**

**MAE: 57.50739925362372**

**RMSE: 79.90103046723014**

- ElasticNet ( alpha=0.01, l1\_ratio=0.5 ) daje gotovo identične rezultate kao osnovna linearna regresija, pa regularizacija ovde nije donela značajno poboljšanje.



- **Koeficijenti sva tri modela ( linearna regresija, ElasticNet i ElasticNet treniran na objedinjenom trening i validacionom skupu ) gotovo se u potpunosti poklapaju, pa ni regularizacija ni uključivanje validacionog skupa nemaju značajan uticaj na ono što model uči niti na njegove performanse.**

# Linearni SVM

## Linear SVM - TEST

**R2: 0.19366168393682714**

**MAE: 54.35658525663164**

**RMSE: 83.8635183517107**


# SVM sa RBF kernelom

## RBF SVR - TEST

**R2: 0.6523868892747569**

**MAE: 32.51873731159663**


**RMSE: 55.063334026406714**



- Heat mapa pokazuje da R<sup>2</sup> raste sa povećanjem oba hiperparametra ( C i gamma ), pri čemu su najbolje performanse za veće vrednosti, dok su za male vrednosti rezultati blizu nule ili negativni.

# Poređenje modela

Poređenje linearnog, kernelizovanog SVM modela i kernelizovanog SVM modela na uniji



- Poređenje pokazuje da kernelizovani SVM ( RBF SVR ) ima znatno bolji  $R^2$  od linearnog SVM-a, a treniranje na uniji trening i validacionog skupa donosi dodatno malo poboljšanje, što potvrđuje da su odnosi u podacima nelinearni.

# KNN

## KNN

**R2: 0.6194203019885463**

**MAE: 33.097169811320754**

**RMSE: 57.6152218436993**


## KNN - unija

### KNN - unija trening i validacije

**R2: 0.6771087657862582**

**MAE: 29.484687953555877**

**RMSE: 53.06920202144586**



- KNN model treniran na uniji trening i validacionog skupa ostvaruje bolje rezultate u sve tri metrike ( viši  $R^2$ , niži MAE i RMSE ), što pokazuje da bolje generalizuje kada ima više podataka za učenje.



# Random Forest

## Random Forest - TEST

**R2: 0.7987062498074355**

**MAE: 25.66472423802612**


**RMSE: 41.9015004976553**



- Heat mapa pokazuje da veće vrednosti broja stabala i dozvoljene dubine vode ka boljem R<sup>2</sup>, odnosno boljim performansama Random Forest modela.
- Grafik značaja atributa pokazuje da Random Forest ne koristi sve attribute podjednako, pri čemu pojedini vremenski i meteorološki atributi najviše doprinose predviđanju PM2.5.


# Poređenje modela

Poređenje Random Forest modela i Random Forest modela na uniji trening i validacije




- **Random Forest treniran na uniji trening i validacionog skupa postiže bolje rezultate u sve tri metrike, što pokazuje da dodatni podaci doprinose tačnijem predviđanju.**


# Neuronske mreže



- **Trening i validaciona greška naglo opadaju u prvim epohama, a zatim sporije, ostajući bliske, što ukazuje da nema izraženog preprilagođavanja.**



- **Kod druge arhitekture trening i validaciona greška takođe opadaju tokom obučavanja i ostaju bliske, uz manje oscilacije na validaciji, bez znakova izraženog preprilagođavanja.**



- **Kod treće, najsloženije arhitekture greška opada bez izraženog preprilagođavanja, a niže vrednosti u odnosu na prethodne arhitekture ukazuju na bolje performanse.**

# Poređenje arhitektura

|   | Model   | R2       | MAE       | RMSE      |
|---|---------|----------|-----------|-----------|
| 0 | Model 1 | 0.588049 | 40.268059 | 57.372437 |
| 1 | Model 2 | 0.618950 | 38.319176 | 55.178692 |
| 2 | Model 3 | 0.709524 | 32.348281 | 48.176542 |

- Poređenje pokazuje da performanse rastu sa složenošću mreže, pri čemu treća arhitektura ostvaruje najbolji  $R^2$  i najniže MAE i RMSE vrednosti na validacionom skupu.

## Potpuno povezana neuronska mreža - TEST


**R2: 0.696601027736018**

**MAE: 33.48608207066796**

**RMSE: 51.44243085704403**

- Najbolja neuronska mreža na test skupu objašnjava približno 70% varijabilnosti PM2.5, uz rezultate bliske onima na validacionom skupu, što pokazuje da model dobro generalizuje na nove podatke.

# Poređenje R<sup>2</sup> score-a najboljih modela



- Random Forest ostvaruje najbolji rezultat (  $R^2 \approx 0,80$  ), a slede ga neuronska mreža, SVM i KNN, koji uspešno modeluju složene odnose među atributima.
- Linearni modeli ( ElasticNet i linearni SVM ) postižu znatno slabije rezultate, što pokazuje da linearna pretpostavka nije adekvatna za ovaj problem.



**Hvala na pažnji!**